

Toleranzintervalle: Theorie, Verfahren und automatisierte Berechnung

Frank Zimmermann | Technische Dokumentation

Februar 2026

Zusammenfassung. Dieses Dokument beschreibt die mathematischen Grundlagen und die softwaretechnische Implementierung eines automatisierten Toleranzintervall-Rechners. Ausgehend von der Abgrenzung zu Konfidenzintervallen und Prädiktionsintervallen werden vier Verfahren entwickelt: verteilungsfrei (Ordnungsstatistiken), normalverteilt (k -Faktor), lognormalverteilt (Transformation) und Weibull-basiert (parametrischer Bootstrap). Für das verteilungsfreie Verfahren wird eine Optimierung vorgestellt, die durch Verschieben eines gleitenden Fensters über die Ordnungsstatistiken das engste Intervall bei gegebener Konfidenz findet – eine Verbesserung gegenüber dem in der Standardliteratur (Meeker et al., 2017) beschriebenen symmetrischen Ansatz. Ein Entscheidungsalgorithmus wählt automatisch das geeignete Verfahren anhand von Stichprobenumfang und Verteilungstests aus. Die Implementierung erfolgt in Python mit PySide6-Oberfläche.

Inhaltsverzeichnis

1	Warum Toleranzintervalle?	2	6.5	Toleranzintervall via parametrischem Bootstrap	6
1.1	Drei Arten von Intervallen	2	6.6	Weibull-Quantilfunktion	6
1.2	Praktische Motivation	2	7	Automatische Methodenwahl	6
2	Verteilungsfreies Toleranzintervall	2	7.1	Entscheidungslogik	6
2.1	Grundidee	2	7.2	Begründung der Reihenfolge	6
2.2	Zweiseitiges Intervall	3	8	Einseitige Toleranzintervalle	7
2.3	Symmetrisches Trimmen nach Meeker	3	8.1	Oberes Toleranzintervall	7
2.4	Optimierung: Gleitendes Fenster	3	8.2	Unteres Toleranzintervall	7
2.5	Vergleich mit Meeker: Compound-Amount-Daten	3	8.3	Anwendung	7
2.6	Einseitiges Intervall	4	9	Verifikation und Tests	7
2.7	Mindeststichprobengrößen	4	9.1	Tests der Mindeststichprobengrößen	8
3	Normalverteilungs-Toleranzintervall	4	9.2	Tests des k -Faktors	8
3.1	Voraussetzung	4	9.3	Tests der Methodenwahl	8
3.2	Der k -Faktor	4	9.4	Tests der Intervallgrenzen	8
3.2.1	Einseitiger Fall	4	10	Praktische Hinweise	8
3.2.2	Zweiseitiger Fall	5	10.1	Stichprobengröße	8
3.3	Verhalten des k -Faktors	5	10.2	Umgang mit Ausreißern	8
4	Normalitätstest: Shapiro-Wilk	5	10.3	Wahl der Abdeckung und Konfidenz	8
4.1	Teststatistik	5	10.4	Grenzen des Fallback-Verfahrens	8
4.2	Testentscheidung	5	11	Mathematische Zusammenfassung	8
5	Lognormal-Toleranzintervall	5	12	Implementierung	8
5.1	Voraussetzung	5	12.1	Architektur	8
5.2	Verfahren	5	12.2	Abhängigkeiten	8
5.3	Verteilungstest	5	12.3	Projektstruktur	9
6	Weibull-Toleranzintervall	5	13	Durchgerechnete Beispiele	9
6.1	Die Weibull-Verteilung	6	13.1	Beispiel 1: Normal – Messwerte einer Fertigung	9
6.2	Interpretation des Formparameters	6	13.2	Beispiel 2: Verteilungsfrei – Meeker-Referenzdaten	9
6.3	Parameterschätzung	6			
6.4	Anpassungstest	6			

13.3 Beispiel 3: Lognormal – Konzentrations-	9
13.4 Beispiel 4: Weibull – Lebensdauerdaten	10
14 Herleitung der k-Faktor-Formel	10
14.1 Einseitiger Fall – exakte Lösung	10
14.2 Zweiseitiger Fall – Approximation	10
15 Vergleich der Verfahren	10
15.1 Intervallbreite	10
15.2 Wann welches Verfahren?	10
15.3 Rechenaufwand	10
16 Abgrenzung: TI vs. KI vs. Prädiktions-	11
intervall	
17 Zusammenhang mit Prozessfähigkeits-	11
kennzahlen	
17.1 Definitionen	11
17.2 Verbindung zu Toleranzintervallen	11
18 Bootstrap-Verfahren im Detail	11
18.1 Warum Bootstrap?	11
18.2 Parametrischer vs. nichtparametrischer	
Bootstrap	11
18.3 Konvergenzverhalten	11
19 Sensitivitätsanalyse	12
19.1 Einfluss des Signifikanzniveaus α_s	12
19.2 Einfluss von n auf die Intervallbreite	12
20 Ausblick: Zensierte Daten	12
20.1 Zensierungsarten	12
20.2 Auswirkung auf Toleranzintervalle	12
21 Fehlerquellen und häufige Missverständ-	12
nisse	
21.1 Verwechslung von Konfidenz und Abde-	
ckung	12
21.2 Normalitätsannahme bei kleinem n	12
21.3 Multiple Testproblematik	12
22 Referenzen und weiterführende Literatur	13
A Formelsammlung	13
A.1 Verteilungsfreies TI	13
A.2 Normal-TI	13
A.3 Lognormal-TI	13
A.4 Weibull-TI	13
A.5 Shapiro-Wilk-Teststatistik	14
A.6 KS-Teststatistik (Weibull-GoF)	14
A.7 Prozessfähigkeit	14

1 Warum Toleranzintervalle?

In der industriellen Praxis stehen Ingenieure und Qualitätssicherer regelmäßig vor der Frage: *Welchen Bereich*

decken die Messwerte meiner Produktion ab? Diese Frage klingt einfach, aber die Antwort hängt davon ab, was genau man wissen möchte.

1.1 Drei Arten von Intervallen

Gegeben seien n unabhängige Messwerte $x_1, \dots, x_n$ aus einer Grundgesamtheit mit unbekannter Verteilung F .

Definition 1.1 (Konfidenzintervall für den Mittelwert). Ein $100(1 - \alpha)\%$ -Konfidenzintervall ist ein Intervall $[L, U]$, sodass

$$\mathbb{P}(\mu \in [L, U]) \geq 1 - \alpha \quad (1)$$

wobei $\mu = \mathbb{E}[X]$ der wahre Populationsmittelwert ist. Das Konfidenzintervall macht eine Aussage über einen *Parameter*.

Definition 1.2 (Prädiktionsintervall). Ein $100(1 - \alpha)\%$ -Prädiktionsintervall ist ein Intervall $[L, U]$, sodass ein *einzelner zukünftiger* Messwert X_{n+1} mit Wahrscheinlichkeit $\geq 1 - \alpha$ in $[L, U]$ fällt.

Definition 1.3 (Toleranzintervall). Ein $100p/100(1 - \alpha)\%$ -Toleranzintervall ist ein Intervall $[L, U]$, das *mindestens den Anteil p der Grundgesamtheit* überdeckt, und zwar mit einer Konfidenz von $1 - \alpha$. Formal:

$$\mathbb{P}(\mathbb{P}(X \in [L, U]) \geq p) \geq 1 - \alpha \quad (2)$$

Der entscheidende Unterschied: Das Konfidenzintervall schätzt einen Parameter (Punkt), das Prädiktionsintervall sagt einen einzelnen Wert voraus, das Toleranzintervall charakterisiert einen *Anteil der Population*.

1.2 Praktische Motivation

Toleranzintervalle beantworten Fragen wie:

- *Welcher Bereich umfasst 95% aller produzierten Teile?*
- *Können wir mit 99% Konfidenz sagen, dass 90% der Lebensdauern über 1000h liegen?*
- *Liegen unsere Messwerte innerhalb der Spezifikation?*

In der industriellen Qualitätssicherung nach ISO 16269 sind Toleranzintervalle das Standardwerkzeug, um aus Stichproben auf die Streuung der Grundgesamtheit zu schließen.

Hinweis: Ein 95/95-Toleranzintervall bedeutet: Mit 95% Konfidenz überdeckt das Intervall mindestens 95% der Population. Beides – Abdeckung *und* Konfidenz – muss angegeben werden.

2 Verteilungsfreies Toleranzintervall

2.1 Grundidee

Das verteilungsfreie Verfahren macht *keine Annahme* über die Form der Grundgesamtheit. Es nutzt ausschließlich die Ordnungsstatistiken der Stichprobe.

Definition 2.1 (Ordnungsstatistiken). Seien $x_1, \dots, x_n$ die Messwerte. Die Ordnungsstatistiken sind die aufsteigend sortierten Werte:

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$$

2.2 Zweiseitiges Intervall

Für das Intervall $[x_{(\ell)}, x_{(u)}]$ mit $1 \leq \ell < u \leq n$ ist die Wahrscheinlichkeit, dass dieses Intervall mindestens den Anteil p der Population überdeckt, gegeben durch die *Coverage Probability of a Tolerance Interval* (Meeker et al., 2017, Formel 5.9):

Satz 2.2 (CPTI-Formel). Die Konfidenz für das Intervall $[x_{(\ell)}, x_{(u)}]$ ist

$$\text{CPTI}(n, \ell, u, p) = \sum_{i=0}^{d-1} \binom{n}{i} p^i (1-p)^{n-i}$$

wobei $d = u - \ell$ der *Span* (Anzahl der Werte zwischen den Grenzen) ist. Dies entspricht der Binomial-CDF: $\text{CPTI} = F_{\text{Binom}}(d-1; n, p)$.

Hinweis: Die Konfidenz hängt **nur vom Span** $d = u - \ell$ **ab**, nicht von der Position (ℓ, u) innerhalb der sortierten Stichprobe. Diese Eigenschaft ist der Schlüssel zur weiter unten beschriebenen Optimierung (section 2.4).

Für den Spezialfall $\ell = 1, u = n$ (äußerste Ordnungsstatistiken, $d = n - 1$) vereinfacht sich die Formel:

Satz 2.3 (Konfidenz für Minimum und Maximum). Für den Spezialfall $d = n - 1$ (Intervall $[x_{(1)}, x_{(n)}]$) gilt:

$$C(n, p) = 1 - np^{n-1} + (n-1)p^n$$

Beweis. Folgt direkt aus Satz 2.2 mit $d = n - 1$: Die Summation über die Binomialterme ergibt nach Umformung die geschlossene Form $1 - np^{n-1} + (n-1)p^n$. $\square$

Das *minimale* n für vorgegebene Abdeckung p und Konfidenz $1 - \alpha$ ergibt sich durch Lösen von

$$1 - np^{n-1} + (n-1)p^n \geq 1 - \alpha \quad (3)$$

nach dem kleinsten ganzzahligen n .

2.3 Symmetrisches Trimmen nach Meeker

Der klassische Ansatz (Meeker et al., 2017, Kap. 5) bestimmt einen Parameter ν aus Tabelle J.11, der angibt, wie viele Ordnungsstatistiken von den Rändern entfernt werden. Die Aufteilung erfolgt symmetrisch:

$$\ell = \lfloor \nu/2 \rfloor, \quad u = n - \lfloor \nu/2 \rfloor + 1$$

Für den Fall, dass die resultierende Konfidenz den geforderten Wert $1 - \alpha$ deutlich übersteigt, beschreibt Meeker eine *Interpolationsmethode* (Example 5.10): Man bildet einen gewichteten Durchschnitt zwischen dem konservativen und dem nichtkonservativen Randpaar.

Dieser Ansatz hat zwei Nachteile:

1. **Symmetrische Aufteilung:** Bei schiefen Verteilungen liegt die Datenspannweite nicht symmetrisch um das Zentrum. Das symmetrische Trimmen kann ein unnötig breites Intervall ergeben.
2. **Interpolation:** Die Interpolation zwischen konservativem und nichtkonservativem Intervall ist nicht mehr streng verteilungsfrei und kann das Intervall sogar *breiter* machen als das konservative Ergebnis (siehe section 2.5).

2.4 Optimierung: Gleitendes Fenster

Da die Konfidenz gemäß Satz 2.2 ausschließlich vom Span d abhängt, kann man das Fenster $[\ell, \ell + d]$ über alle zulässigen Positionen $\ell = 1, \dots, n - d$ verschieben und dasjenige wählen, für das die Intervallbreite $x_{(\ell+d)} - x_{(\ell)}$ minimal wird.

Satz 2.4 (Optimales verteilungsfreies TI). Sei d^* der minimale Span mit $F_{\text{Binom}}(d^* - 1; n, p) \geq 1 - \alpha$, und sei

$$\ell^* = \arg \min_{\ell \in \{1, \dots, n-d^*\}} (x_{(\ell+d^*)} - x_{(\ell)}).$$

Dann ist $[x_{(\ell^*)}, x_{(\ell^*+d^*)}]$ das engste verteilungsfreie $(p, 1-\alpha)$ -Toleranzintervall mit der Konfidenzgarantie:

$$\text{CPTI}(n, \ell^*, \ell^* + d^*, p) = F_{\text{Binom}}(d^* - 1; n, p) \geq 1 - \alpha$$

Beweis. Die Konfidenz ist invariant unter Verschiebung des Fensters (da sie nur von d abhängt). Also hat das verschobene Intervall exakt dieselbe statistische Garantie wie jedes andere Intervall mit gleichem d . Die Wahl von ℓ^* minimiert lediglich die Breite – ein reiner Informationsgewinn ohne Verlust der Konfidenz. $\square$

Der Algorithmus läuft in $O(n)$ – ein einziger Durchlauf über die sortierten Daten genügt. Die Implementierung ist trivial:

Algorithmus 1: Optimales verteilungsfreies TI

Eingabe: Sortierte Daten $x_{(1)}, \dots, x_{(n)}$;

Abdeckung p ; Konfidenz $1 - \alpha$

Ausgabe: Optimales Intervall $[x_{(\ell^*)}, x_{(u^*)}]$

- 1 Finde d^* als kleinstes d mit $F_{\text{Binom}}(d-1; n, p) \geq 1 - \alpha$;
 - 2 $w^* \leftarrow \infty$; $\ell^* \leftarrow 1$;
 - 3 **for** $\ell \leftarrow 1$ **to** $n - d^*$ **do**
 - 4 $w \leftarrow x_{(\ell+d^*)} - x_{(\ell)}$;
 - 5 **if** $w < w^*$ **then** $w^* \leftarrow w$; $\ell^* \leftarrow \ell$;
 - 6 **return** $[x_{(\ell^*)}, x_{(\ell^*+d^*)}]$
-

2.5 Vergleich mit Meeker: Compound-Amount-Daten

Als Testdaten verwenden wir die 100 Messwerte aus Meeker et al. (2017, Table 5.1): geordnete Konzentrationen (ppm) eines chemischen Prozesses, mit $x_{(1)} = 1.49$ und $x_{(100)} = 58.11$. Die Daten sind deutlich rechtsschief.

Gesucht: zweiseitiges TI mit $p = 0.90$, $1 - \alpha = 0.95$.

Tabelle 1: Vergleich der Verfahren für die Meeker-Daten ($n = 100$, $p = 0.90$, $1 - \alpha = 0.95$)

Methode	ℓ	u	Konfidenz	Breite
Naiv ($x_{(1)}, x_{(n)}$)	1	100	99.97%	56.62
Meeker Ex. 5.9 (symm.)	2	98	97.63%	35.66
Meeker Ex. 5.10 (interp.)	–	–	$\approx 95\%$	37.78
Optimiert (unser)	1	97	97.63%	31.75

Die Ergebnisse zeigen:

1. Der **naive Ansatz** ($\ell = 1, u = 100$) liefert zwar eine Konfidenz von 99.97%, ist aber mit einer Breite von 56.62 stark überkonservativ – die statistisch nicht genutzte Reservekonfidenz ist verschwendete Information.
2. **Meeker Ex. 5.9** trimmt symmetrisch ($\nu = 5 \Rightarrow \ell = 2, u = 98$) und reduziert den Span auf $d = 96$ (CP-TI = 0.9763). Das Intervall $[1.66, 37.32]$ ist deutlich enger.
3. **Meeker Ex. 5.10** interpoliert zwischen dem konservativen und nichtkonservativen Intervall, um die Konfidenz auf genau 95% zu treffen. Paradoxe Weise wird das Intervall dadurch *breiter* (37.78 statt 35.66), weil die Interpolation die obere Grenze Richtung $x_{(99)} = 53.43$ zieht.
4. **Unsere Optimierung** nutzt denselben Span $d = 96$ wie Meeker und hat identische Konfidenz (97.63%), verschiebt aber das Fenster nach $\ell = 1, u = 97$. Die obere Grenze fällt von 37.32 auf 33.24 – eine **Reduktion der Intervallbreite um 11%**.

Hinweis: Bei symmetrischen Daten liefert die Optimierung dasselbe Ergebnis wie Meekers symmetrischer Ansatz. Der Vorteil zeigt sich gerade bei schiefen Verteilungen, wo die Extremwerte auf einer Seite konzentriert sind – also genau dann, wenn man das verteilungsfreie Verfahren braucht, weil die Normalverteilung nicht passt.

Warum verwendet Meeker nicht diese Optimierung? Der Grund ist historisch: Das Tabellensystem (Table J.11) wurde für die Taschenrechner-Ära entworfen, in der man einen Parameter ν nachschlägt und symmetrisch aufteilt. Die Fenster-Optimierung braucht Zugriff auf die gesamten sortierten Daten und eine Schleife – trivial für einen Rechner, aber nicht für Papier und Bleistift. In der zweiten Auflage (2017) wurde das Framework beibehalten, obwohl Meeker R verwendet.

2.6 Einseitiges Intervall

Für ein oberes einseitiges Toleranzintervall $(-\infty, x_{(n)})$ gilt:

$$\mathbb{P}(F(x_{(n)}) \geq p) = 1 - p^n \quad (4)$$

Das minimale n folgt aus $1 - p^n \geq 1 - \alpha$:

$$n \geq \frac{\ln \alpha}{\ln p} \quad (5)$$

Analog für das untere einseitige Intervall $[x_{(1)}, \infty)$.

2.7 Mindeststichprobengrößen

Table 2 zeigt die resultierenden Mindest- n für gängige Kombinationen von p und $1 - \alpha$.

Tabelle 2: Minimales n für verteilungsfreie TI ($r = 1, s = n$)

p	$1 - \alpha$	einseitig	zweiseitig
0.90	0.90	22	38
0.90	0.95	29	46
0.90	0.99	44	64
0.95	0.90	45	77
0.95	0.95	59	93
0.95	0.99	90	130
0.99	0.90	230	388
0.99	0.95	299	473
0.99	0.99	459	662

Warnung: Für $p = 0.99$ bei $1 - \alpha = 0.99$ sind **662 Messwerte** nötig. Bei teuren Prüfungen (z. B. Lebensdauertests) ist das verteilungsfreie Verfahren oft nicht praktikabel – man muss dann auf ein parametrisches Verfahren ausweichen.

3 Normalverteilungs-Toleranzintervall

3.1 Voraussetzung

Die Messwerte stammen aus einer Normalverteilung: $X_i \sim \mathcal{N}(\mu, \sigma^2)$ mit unbekanntem μ und σ .

3.2 Der k -Faktor

Das Toleranzintervall hat die Form:

$$[\bar{x} - k \cdot s, \bar{x} + k \cdot s] \quad (6)$$

wobei $\bar{x}$ der Stichprobenmittelwert und $s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$ die Stichprobenstandardabweichung ist.

Der Faktor k muss so bestimmt werden, dass eq. (2) erfüllt ist.

3.2.1 Einseitiger Fall

Für ein oberes einseitiges Toleranzintervall $(-\infty, \bar{x} + k \cdot s]$ folgt k aus der *nichtzentralen t -Verteilung*:

Satz 3.1 (k -Faktor, einseitig). Der einseitige k -Faktor erfüllt:

$$k = \frac{t_{n-1, 1-\alpha, \delta}}{\sqrt{n}} \quad (7)$$

wobei $t_{n-1, 1-\alpha, \delta}$ das $(1-\alpha)$ -Quantil der nichtzentralen t -Verteilung mit $n-1$ Freiheitsgraden und Nichtzentralitätsparameter $\delta = z_p \sqrt{n}$ ist, und $z_p = \Phi^{-1}(p)$ das p -Quantil der Standardnormalverteilung.

Die Herleitung nutzt, dass $T = \frac{\bar{x} - \mu}{s/\sqrt{n}}$ einer t -Verteilung mit $n-1$ Freiheitsgraden folgt und die Toleranzforderung auf ein Quantilproblem der nichtzentralen t -Verteilung zurückgeführt werden kann.

3.2.2 Zweiseitiger Fall

Der zweiseitige Fall ist analytisch komplexer. Eine gängige Approximation nach HOWE (1969) lautet:

Satz 3.2 (k -Faktor, zweiseitig – Howe-Approximation).

$$k = z_{(1+p)/2} \cdot \sqrt{\frac{(n-1)(1+1/n)}{\chi_{1-\alpha, n-1}^2}} \quad (8)$$

wobei $\chi_{1-\alpha, n-1}^2$ das $(1-\alpha)$ -Quantil der χ^2 -Verteilung mit $n-1$ Freiheitsgraden ist (unteres Quantil).

Die Idee: Die Unsicherheit in $\bar{x}$ wird durch den Faktor $(1+1/n)$ berücksichtigt, die Unsicherheit in s^2 durch die χ^2 -Verteilung.

3.3 Verhalten des k -Faktors

Für $n \rightarrow \infty$ konvergiert k gegen $z_{(1+p)/2}$, d. h. die Unsicherheit in der Schätzung von μ und σ verschwindet. Für kleines n ist k deutlich größer, was die Schätzunsicherheit kompensiert. Table 3 zeigt einige Werte.

Tabelle 3: k -Faktoren für $p = 0.95$, $1 - \alpha = 0.95$ (zweiseitig, Howe-Approximation)

n	k
5	4.4141
10	3.0793
15	2.7523
20	2.5836
30	2.4183
50	2.2689
100	2.1330
∞	1.9600

4 Normalitätstest: Shapiro-Wilk

Bevor das Normal-Toleranzintervall angewendet wird, muss die Normalverteilungs-Annahme geprüft werden. Der Shapiro-Wilk-Test ist für kleine bis mittlere Stichproben ($n \leq 5000$) einer der mächtigsten Tests.

4.1 Teststatistik

Definition 4.1 (Shapiro-Wilk-Teststatistik).

$$W = \frac{(\sum_{i=1}^n a_i x_{(i)})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (9)$$

wobei $x_{(i)}$ die Ordnungsstatistiken sind und die Gewichte a_i aus der Kovarianzmatrix der Ordnungsstatistiken der Standardnormalverteilung berechnet werden:

$$(a_1, \dots, a_n) = \frac{\mathbf{m}^T \mathbf{V}^{-1}}{\|\mathbf{V}^{-1} \mathbf{m}\|} \quad (10)$$

mit $\mathbf{m} = \mathbb{E}[\mathbf{Z}_{(i)}]$ den erwarteten Ordnungsstatistiken und $\mathbf{V}$ deren Kovarianzmatrix.

4.2 Testentscheidung

- H_0 : Die Daten stammen aus einer Normalverteilung
- H_1 : Die Daten stammen nicht aus einer Normalverteilung
- Ablehnung von H_0 , wenn der p -Wert $< \alpha$ (typisch: $\alpha = 0.05$)

Hinweis: Der Shapiro-Wilk-Test testet auf *Abweichung* von der Normalität. Ein hoher p -Wert *bestätigt* nicht die Normalverteilung – er sagt nur, dass die Daten nicht signifikant davon abweichen. Bei kleinem n hat der Test wenig Macht.

5 Lognormal-Toleranzintervall

5.1 Voraussetzung

Die Messwerte $x_i > 0$ folgen einer Lognormalverteilung, d. h. $\ln(x_i) \sim \mathcal{N}(\mu_{\ln}, \sigma_{\ln}^2)$.

Typische Anwendungen: Konzentrationen, Einkommen, Partikelgrößen, bestimmte Lebensdauern.

5.2 Verfahren

Die Grundidee ist denkbar einfach: Man transformiert die Daten auf die Log-Skala, berechnet dort ein Normal-Toleranzintervall und transformiert zurück.

1. Berechne $y_i = \ln(x_i)$
2. Berechne $\bar{y}$ und s_y auf der Log-Skala
3. Bestimme k nach eq. (8) (oder eq. (7))
4. Das Toleranzintervall auf der Originalskala ist:

$$[\exp(\bar{y} - k \cdot s_y), \exp(\bar{y} + k \cdot s_y)] \quad (11)$$

5.3 Verteilungstest

Die Lognormalitäts-Annahme wird geprüft, indem der Shapiro-Wilk-Test auf die *log-transformierten* Daten $y_i = \ln(x_i)$ angewendet wird.

Hinweis: Das Lognormal-Toleranzintervall ist *asymmetrisch* auf der Originalskala – die obere Grenze kann sehr viel weiter vom Median entfernt sein als die untere. Das ist physikalisch sinnvoll für rechtsschiefe Daten.

6 Weibull-Toleranzintervall

6.1 Die Weibull-Verteilung

Die Weibull-Verteilung ist *das* Standardmodell für Lebensdauer- und Zuverlässigkeitsanalysen. Ihre Dichte lautet:

$$f(x; c, \lambda) = \frac{c}{\lambda} \left(\frac{x}{\lambda}\right)^{c-1} \exp\left[-\left(\frac{x}{\lambda}\right)^c\right] \quad (12)$$

für $x > 0$, mit Formparameter $c > 0$ und Skalenparameter $\lambda > 0$.

Die Verteilungsfunktion ist:

$$F(x) = 1 - \exp\left[-\left(\frac{x}{\lambda}\right)^c\right] \quad (13)$$

6.2 Interpretation des Formparameters

Der Parameter c bestimmt die Form der Ausfallrate:

- $c < 1$: abnehmende Ausfallrate (Frühausfälle, *infant mortality*)
- $c = 1$: konstante Ausfallrate (Exponentialverteilung)
- $c > 1$: zunehmende Ausfallrate (Alterung, Verschleiß)
- $c \approx 3.6$: annähernd normalverteilt

6.3 Parameterschätzung

Die Parameter c und λ werden per *Maximum-Likelihood-Estimation* (MLE) geschätzt. Die Log-Likelihood ist:

$$\ell(c, \lambda) = n \ln c - nc \ln \lambda + (c-1) \sum_{i=1}^n \ln x_i - \sum_{i=1}^n \left(\frac{x_i}{\lambda}\right)^c \quad (14)$$

Die Maximierung erfolgt numerisch (z.B. über `scipy.stats.weibull_min.fit`).

6.4 Anpassungstest

Da `scipy.stats.anderson` die Weibull-Verteilung nicht direkt unterstützt, verwenden wir einen *Kolmogorow-Smirnow-Test mit Monte-Carlo-Korrektur* (Lilliefors-Ansatz):

1. Fitte Weibull(c, λ) per MLE an die Daten
2. Berechne die KS-Statistik:

$$D_n = \sup_x |F_n(x) - F(x; \hat{c}, \hat{\lambda})| \quad (15)$$

3. Simuliere $N_{MC} = 500$ Stichproben aus Weibull($\hat{c}, \hat{\lambda}$)
4. Für jede Simulation: fitte neu und berechne $D_n^{(j)}$
5. Der Monte-Carlo- p -Wert ist:

$$p_{MC} = \frac{1}{N_{MC}} \sum_{j=1}^{N_{MC}} \mathbf{1}[D_n^{(j)} \geq D_n] \quad (16)$$

Warnung: Der naive KS- p -Wert (ohne Monte-Carlo-Korrektur) ist *zu liberal*, wenn die Parameter aus denselben Daten geschätzt werden. Die Korrektur via Simulation ist essenziell (Lilliefors-Problem).

6.5 Toleranzintervall via parametrischem Bootstrap

Für die Weibull-Verteilung existiert keine geschlossene Formel für den k -Faktor analog zum Normalfall. Stattdessen verwenden wir *parametrischen Bootstrap*:

1. Fitte Weibull(c, λ) an die Originaldaten
2. Für $b = 1, \dots, B$ (typisch $B = 2000$):
 - (a) Generiere n Werte aus Weibull($\hat{c}, \hat{\lambda}$)
 - (b) Fitte neu: $\hat{c}^{(b)}, \hat{\lambda}^{(b)}$
 - (c) Berechne die Zielquantile:

$$q_L^{(b)} = F^{-1}\left(\frac{1-p}{2}; \hat{c}^{(b)}, \hat{\lambda}^{(b)}\right) \quad (17)$$

$$q_U^{(b)} = F^{-1}\left(\frac{1+p}{2}; \hat{c}^{(b)}, \hat{\lambda}^{(b)}\right) \quad (18)$$

3. Die Konfidenzgrenzen des Toleranzintervalls sind:

$$L = Q_{\alpha/2}\left(\{q_L^{(b)}\}_{b=1}^B\right) \quad (19)$$

$$U = Q_{1-\alpha/2}\left(\{q_U^{(b)}\}_{b=1}^B\right) \quad (20)$$

wobei Q_γ das γ -Quantil der Bootstrap-Verteilung bezeichnet.

Die Idee: Die Bootstrap-Verteilung der Quantilschätzer bildet die Parameterunsicherheit ab. Indem wir konservative Perzentile wählen (unteres Ende der unteren Grenze, oberes Ende der oberen), erhalten wir ein Toleranzintervall mit der geforderten Konfidenz.

6.6 Weibull-Quantilfunktion

Die Quantilfunktion der Weibull-Verteilung hat eine geschlossene Form:

$$F^{-1}(q) = \lambda \cdot (-\ln(1-q))^{1/c} \quad (21)$$

Dies macht die Bootstrap-Berechnung numerisch effizient.

7 Automatische Methodenwahl

Der zentrale Beitrag der Implementierung ist ein Entscheidungs-Algorithmus, der automatisch das geeignetste Verfahren auswählt.

7.1 Entscheidungslogik

7.2 Begründung der Reihenfolge

Die Priorisierung folgt dem Prinzip *maximaler Informationsnutzung*:

1. **Parametrische Verfahren zuerst** (Normal, Lognormal, Weibull): Diese nutzen *alle* n Datenpunkte ($\bar{x}$, s , bzw. MLE-Schätzer) und liefern daher engere Intervalle. Besonders bei kleinem n ist der Informationsgewinn gegenüber dem verteilungsfreien Verfahren erheblich.

Algorithmus 2: Automatische Methodenwahl (parametrisch zuerst)

```

Input: Daten  $x_1, \dots, x_n$ ; Abdeckung  $p$ ;
          Konfidenz  $1 - \alpha$ ; Seite; Shapiro- $\alpha_s$ 
Output: Toleranzintervall  $[L, U]$  mit Methode
/* Schritt 1-3: Parametrische Verfahren
   (nutzen alle  $n$  Datenpunkte) */
1 if  $n \geq 3$  then
2    $(W, p_W) \leftarrow \text{Shapiro-Wilk}(x_1, \dots, x_n)$ ;
3   if  $p_W \geq \alpha_s$  then
4     return Normal-TI ( $k$ -Faktor);
5   end
6 end
7 if  $\forall i : x_i > 0$  und  $n \geq 3$  then
8    $(W, p_W) \leftarrow \text{Shapiro-Wilk}(\ln x_1, \dots, \ln x_n)$ ;
9   if  $p_W \geq \alpha_s$  then
10    return Lognormal-TI ( $k$ -Faktor auf
        Log-Skala);
11  end
12 end
13 if  $\forall i : x_i > 0$  und  $n \geq 5$  then
14    $(c, \lambda, D_n, p_{MC}) \leftarrow \text{Weibull-GoF}$ ;
15   if  $p_{MC} \geq \alpha_s$  then
16     return Weibull-TI (parametrischer
        Bootstrap);
17  end
18 end
   /* Schritt 4: Verteilungsfrei (braucht
      viele Daten) */
19  $n_{\min} \leftarrow \min\_n(p, 1 - \alpha, \text{Seite})$ ;
20 if  $n \geq n_{\min}$  then
21   return Verteilungsfreies TI
        (Ordnungsstatistiken, Fensteroptimierung);
22 end
   /* Schritt 5: Letzter Ausweg */
23 return Normal-TI mit Warnung (Fallback);

```

2. **Normal vor Lognormal:** Vermeidet, dass bei annähernd symmetrischen positiven Daten fälschlicherweise Lognormal gewählt wird, nur weil Shapiro-Wilk auf $\ln(x)$ zufällig einen höheren p -Wert liefert.
3. **Weibull nach Lognormal:** Die k -Faktor-Methode ist analytisch sauberer und schneller als der Monte-Carlo-Bootstrap.
4. **Verteilungsfrei als bewusste Wahl:** Kommt erst zum Zug, wenn keine parametrische Verteilung passt und $n \geq n_{\min}$. Bei $n \gg n_{\min}$ kann die Fensteroptimierung (section 2.4) innere Ordnungsstatistiken wählen und liefert dann ein konkurrenzfähiges Intervall.
5. **Fallback:** Wenn weder eine Verteilung passt noch genug Daten für das verteilungsfreie Verfahren vorliegen, liefert das Normal-TI zumindest eine Orientierung – aber mit deutlicher Warnung.

Warnung: Das verteilungsfreie Verfahren ist **nicht** der konservativste oder sicherste Ansatz – bei $n \approx n_{\min}$ ist es der *schwächste*, weil es nur die Extremwerte $x_{(1)}$ und $x_{(n)}$ verwenden kann. Ein parametrisches Verfahren, dessen Verteilungsannahme durch den Shapiro-Wilk-Test gestützt wird, liefert engere und informativere Intervalle.

8 Einseitige Toleranzintervalle

Alle beschriebenen Verfahren unterstützen einseitige Intervalle:

8.1 Oberes Toleranzintervall

$(-\infty, U]$: Garantiert, dass mindestens p der Population *unterhalb* von U liegt.

- Verteilungsfrei: $U = x_{(n)}$, Konfidenz $1 - p^n$
- Normal: $U = \bar{x} + k_{\text{eins}} \cdot s$ mit k nach eq. (7)

8.2 Unteres Toleranzintervall

$[L, \infty)$: Garantiert, dass mindestens p der Population *oberhalb* von L liegt.

- Verteilungsfrei: $L = x_{(1)}$
- Normal: $L = \bar{x} - k_{\text{eins}} \cdot s$

8.3 Anwendung

Einseitige Intervalle sind relevant, wenn nur eine Richtung interessiert:

- Mindest-Lebensdauer: *unteres* TI
- Maximal-Schadstoffgehalt: *oberes* TI
- Mindest-Festigkeit: *unteres* TI

Der einseitige k -Faktor ist kleiner als der zweiseitige (bei gleichem p und $1 - \alpha$), weil die „Wahrscheinlichkeitsmasse“ nicht auf zwei Seiten verteilt werden muss.

9 Verifikation und Tests

Die Implementierung wird durch 21 Unit-Tests abgesichert, die alle wesentlichen Eigenschaften prüfen.

9.1 Tests der Mindeststichprobengrößen

Die berechneten Werte werden gegen die Referenztabellen geprüft:

$$\begin{aligned} n_{\min}(p=0.95, 1-\alpha=0.95, \text{zweiseitig}) &= 93 \\ n_{\min}(p=0.95, 1-\alpha=0.95, \text{einseitig}) &= 59 \\ n_{\min}(p=0.99, 1-\alpha=0.99, \text{zweiseitig}) &= 662 \\ n_{\min}(p=0.90, 1-\alpha=0.90, \text{zweiseitig}) &= 38 \end{aligned}$$

9.2 Tests des k -Faktors

- **Positivität:** $k > 0$ für alle gültigen Parameter
- **Monotonie in n :** $k(n = 20) > k(n = 100)$ – mehr Daten $\Rightarrow$ kleinerer k -Faktor
- **Einseitig < Zweiseitig:** $k_{\text{eins}} < k_{\text{zwei}}$ bei gleichen Parametern

9.3 Tests der Methodenwahl

Die automatische Entscheidungslogik wird mit synthetischen Daten geprüft:

Tabelle 4: Testszzenarien für die automatische Methodenwahl

Szenario	n	Erwartete Methode
$\mathcal{N}(\mu, \sigma^2)$	100	Normal (k -Faktor)
$\mathcal{N}(\mu, \sigma^2)$	20	Normal (k -Faktor)
Lognormal(μ, σ)	25	Lognormal
Bimodal	100	Verteilungsfrei
Bimodal	15	Fallback (Warnung)
Mit NaN-Werten	100	Korrekte n -Zählung
$n < 2$	1	ValueError

9.4 Tests der Intervallgrenzen

- **Verteilungsfrei:** Grenzen = $x_{(1)}$ und $x_{(n)}$; tatsächliche Konfidenz $\geq$ geforderte Konfidenz
- **Normal:** Intervall symmetrisch um $\bar{x}$, d. h. $\bar{x} - L = U - \bar{x}$ (bis Maschinengenauigkeit)
- **Lognormal:** Beide Grenzen strikt positiv; $L < U$; negative Eingabedaten $\Rightarrow$ ValueError
- **Weibull:** Grenzen strikt positiv; negative Eingabedaten $\Rightarrow$ ValueError
- **Einseitig:** Korrekte None-Werte für die offene Seite

10 Praktische Hinweise

10.1 Stichprobengröße

Die Faustregel: *Mehr Daten = engere Intervalle*. Aber die Verbesserung ist nichtlinear – der Sprung von $n = 10$ auf $n = 30$ bringt viel mehr als von $n = 100$ auf $n = 120$.

Für das verteilungsfreie Verfahren ist n eine harte Schwelle: Entweder man hat genug Messwerte oder nicht. Für die parametrischen Verfahren gibt es keine Mindestschwelle, aber bei $n < 10$ sind die Intervalle so breit, dass sie kaum noch nützlich sind.

10.2 Umgang mit Ausreißern

Toleranzintervalle sind *nicht robust* gegen Ausreißer:

- **Verteilungsfrei:** Wird direkt von Extremwerten bestimmt
- **Normal:** $\bar{x}$ und s sind beide ausreißerempfindlich
- **Lognormal:** Etwas robuster durch die Log-Transformation
- **Weibull:** MLE kann durch Ausreißer verzerrt werden

Warnung: Ausreißer sollten *vor* der TI-Berechnung untersucht werden. Einen echten Messfehler zu entfernen ist gerechtfertigt; einen unbequemen, aber validen Messwert zu streichen ist Betrug.

10.3 Wahl der Abdeckung und Konfidenz

Typische Kombinationen in der Praxis:

- **90/90:** Screening, Voruntersuchungen
- **95/95:** Standard in der Qualitätssicherung (ISO 16269)
- **99/95:** Sicherheitskritische Anwendungen
- **99/99:** Luftfahrt, Medizinprodukte

10.4 Grenzen des Fallback-Verfahrens

Wenn keine der getesteten Verteilungen passt, liefert das Normal-TI als Fallback ein Ergebnis. Dieses ist jedoch mit Vorsicht zu genießen:

- Bei schiefen Verteilungen kann die untere Grenze negativ werden (z. B. bei Lebensdauerdaten)
- Die tatsächliche Abdeckung kann deutlich von p abweichen
- Die Empfehlung lautet: mehr Daten sammeln und/oder domänenspezifisches Wissen über die Verteilung einbringen

11 Mathematische Zusammenfassung

Table 5 fasst die zentralen Formeln aller vier Verfahren zusammen.

12 Implementierung

12.1 Architektur

Die Software besteht aus zwei Schichten:

Rechenkern (`tolerance_intervals.py`): Reine Berechnungslogik ohne GUI-Abhängigkeiten. Kann auch standalone als Python-Modul verwendet werden.

GUI (`ti_gui.py`): PySide6-Oberfläche mit Dateneingabe, Parameterkonfiguration und Ergebnisanzeige.

12.2 Abhängigkeiten

- **NumPy:** Datenverarbeitung, Ordnungsstatistiken
- **SciPy:** Verteilungen, k -Faktor (nichtzentrale t -Verteilung, χ^2), Shapiro-Wilk-Test, Weibull-MLE
- **PySide6:** GUI-Framework (Qt für Python)
- **PyInstaller:** Standalone-Binary-Erzeugung

Tabelle 5: Übersicht der Verfahren und Formeln für zweiseitige Toleranzintervalle

Verfahren	Intervall	Schlüsselformel	Voraussetzung
Normal (k -Faktor)	$[\bar{x} - ks, \bar{x} + ks]$	$k = z_{(1+p)/2} \sqrt{\frac{(n-1)(1+1/n)}{\chi_{1-\alpha, n-1}^2}}$	Shapiro-Wilk $p \geq \alpha_s$
Lognormal	$[e^{\bar{y}-ks_y}, e^{\bar{y}+ks_y}]$	k wie Normal, auf $y_i = \ln x_i$	$x_i > 0$, SW auf $\ln x$
Weibull (Boot-strap)	$[Q_{\alpha/2}(q_L^{(b)}), Q_{1-\alpha/2}(q_U^{(b)})]$	$q^{(b)} = \hat{\lambda}^{(b)}(-\ln(1-q))^{1/\hat{e}^{(b)}}$	$x_i > 0$, MC-KS $p \geq \alpha_s$
Verteilungsfrei	$[x_{(\ell^*)}, x_{(\ell^*+d^*)}]$	CPTI = $F_{\text{Binom}}(d^*-1; n, p)$	$n \geq n_{\min}$, kein param. Fit

12.3 Projektstruktur

```

toleranzintervall-rechner/
  main.py           # Einstiegspunkt
  build.py          # Build-Skript
  src/
    tolerance_intervals.py
    ti_gui.py
  tests/
    test_tolerance.py
  .run/             # PyCharm Configs
  pyproject.toml
  requirements.txt
  requirements-dev.txt

```

13 Durchgerechnete Beispiele

Zum besseren Verständnis werden hier alle vier Verfahren an konkreten Daten vorgeführt.

13.1 Beispiel 1: Normal – Messwerte einer Fertigung

Gegeben seien $n = 15$ Durchmesser-Messwerte (in mm):

4.2, 4.5, 4.1, 4.8, 4.3, 4.6, 4.4, 4.7, 4.2, 4.5, 4.3, 4.6, 4.4, 4.3, 4.3

Schritt 1: Verteilungsfrei möglich? Für $p = 0.95$, $1 - \alpha = 0.95$, zweiseitig gilt $n_{\min} = 93$. Da $n = 15 < 93$: nein.

Schritt 2: Normalverteilung? Shapiro-Wilk: $W = 0.9726$, $p = 0.8951 \geq 0.05 \Rightarrow$ Normalverteilung wird nicht abgelehnt.

Schritt 3: k -Faktor berechnen. Mit $n = 15$, $p = 0.95$, $1 - \alpha = 0.95$ (zweiseitig):

$$z_{0.975} = 1.9600$$

$$\chi_{0.05, 14}^2 = 6.5706$$

$$k = 1.9600 \cdot \sqrt{\frac{14 \cdot (1 + 1/15)}{6.5706}} = 2.9548$$

Schritt 4: Intervall berechnen.

$$\bar{x} = 4.4267 \quad s = 0.1981$$

$$L = 4.4267 - 2.9548 \times 0.1981 = 3.8414$$

$$U = 4.4267 + 2.9548 \times 0.1981 = 5.0120$$

Ergebnis: [3.841, 5.012] mm. Mit 95% Konfidenz liegen mindestens 95% aller Durchmesser in diesem Intervall.

13.2 Beispiel 2: Verteilungsfrei – Meeker-Referenzdaten

Gegeben seien die $n = 100$ geordneten Konzentrationsmesswerte (ppm) aus Meeker et al. (2017, Table 5.1) mit $x_{(1)} = 1.49$, $x_{(97)} = 33.24$, $x_{(98)} = 37.32$, $x_{(100)} = 58.11$.

Gesucht: $p = 0.90$, $1 - \alpha = 0.95$, zweiseitig.

Schritt 1: Minimaler Span. Finde kleinstes d mit $F_{\text{Binom}}(d - 1; 100, 0.9) \geq 0.95$. Lösung: $d^* = 96$ mit CPTI = 0.9763.

Schritt 2: Gleitendes Fenster. Verschiebe $[\ell, \ell + 96]$ über $\ell = 1, \dots, 4$:

$$\begin{aligned} \ell = 1 : & [1.49, 33.24] \quad \text{Breite } 31.75 \quad \checkmark \\ \ell = 2 : & [1.66, 37.32] \quad \text{Breite } 35.66 \quad (\text{Meeker}) \\ \ell = 3 : & [2.05, 53.43] \quad \text{Breite } 51.38 \\ \ell = 4 : & [2.24, 58.11] \quad \text{Breite } 55.87 \end{aligned}$$

Alle vier haben identische Konfidenz 97.63%, da $d = 96$ konstant ist. Die Fenster-Optimierung wählt $\ell^* = 1$:

Ergebnis: [1.49, 33.24] mit Konfidenz 97.63%. Meeker gibt [1.66, 37.32] an – 11% breiter bei identischer Konfidenz. Der Vorteil entsteht durch die Rechtsschiefe der Daten: die oberen Extremwerte (53.43, 58.11) erzwingen beim symmetrischen Trimmen ein unnötig breites Intervall.

13.3 Beispiel 3: Lognormal – Konzentrationsdaten

Gegeben seien $n = 25$ Schadstoffkonzentrationen (mg/l), die den Shapiro-Wilk-Test auf Normalität *nicht* bestehen ($p = 0.0035$), aber auf der Log-Skala normalverteilt sind ($p = 0.4382$).

Auf der Log-Skala:

$$\bar{y} = 2.9622 \quad s_y = 0.5234$$

$$k = z_{0.975} \cdot \sqrt{\frac{24 \cdot (1 + 1/25)}{\chi_{0.05, 24}^2}} = 2.6313$$

Rücktransformation:

$$L = \exp(2.9622 - 2.6313 \times 0.5234) = 4.879$$

$$U = \exp(2.9622 + 2.6313 \times 0.5234) = 76.66$$

Ergebnis: [4.88, 76.66] mg/l. Beachte die starke Asymmetrie: die obere Grenze liegt $\approx 15\times$ weiter vom Median entfernt als die untere. Das ist physikalisch sinnvoll für rechtsschiefe Konzentrationen.

13.4 Beispiel 4: Weibull – Lebensdauerdaten

Gegeben seien $n = 30$ Lebensdauern (Stunden) eines Bauteils mit abnehmender Ausfallrate. Shapiro-Wilk lehnt sowohl Normalverteilung ($p = 0.0005$) als auch Lognormalverteilung ($p = 0.0045$) ab.

Weibull-Fit ergibt: $\hat{c} = 0.934$, $\hat{\lambda} = 675.4$ h. Der Monte-Carlo-KS-Test: $p_{MC} = 0.492 \geq 0.05 \Rightarrow$ Weibull wird nicht abgelehnt.

Parametrischer Bootstrap mit $B = 2000$ liefert:

$$[L, U] = [3.47, 4153] \text{ h}$$

Zum Vergleich: Das Normal-Fallback hätte $[-70, 1876]$ h ergeben – eine *negative untere Grenze* für Lebensdauern, was physikalisch sinnlos ist. Das Weibull-TI liefert das korrekte Ergebnis: alle Grenzen sind positiv.

14 Herleitung der k -Faktor-Formel

14.1 Einseitiger Fall – exakte Lösung

Für ein oberes Toleranzintervall $(-\infty, \bar{x} + ks]$ fordern wir:

$$\mathbb{P}\left(\Phi\left(\frac{\bar{x} + ks - \mu}{\sigma}\right) \geq p\right) = 1 - \alpha \quad (22)$$

Sei $Z_p = \Phi^{-1}(p)$. Die Forderung $\frac{\bar{x} + ks - \mu}{\sigma} \geq Z_p$ ist äquivalent zu:

$$k \geq \frac{Z_p \sigma - (\bar{x} - \mu)}{s} = \frac{Z_p}{\frac{s}{\sigma}} - \frac{\bar{x} - \mu}{s} \quad (23)$$

Definiere $T = \frac{\bar{x} - \mu}{s/\sqrt{n}} \sim t_{n-1}$ und verwende $\frac{(n-1)s^2}{\sigma^2} \sim \chi_{n-1}^2$. Dann lässt sich zeigen, dass die Bedingung äquivalent ist zu:

$$k\sqrt{n} \geq T^* \sim t_{n-1}(\delta) \quad (24)$$

wobei T^* einer nichtzentralen t -Verteilung mit $\delta = Z_p\sqrt{n}$ folgt. Also:

$$k = \frac{t_{n-1, 1-\alpha, Z_p\sqrt{n}}}{\sqrt{n}} \quad (25)$$

Dies ist eine *exakte* Lösung, die numerisch über die Quantilfunktion der nichtzentralen t -Verteilung berechnet wird.

14.2 Zweiseitiger Fall – Approximation

Für das zweiseitige Toleranzintervall $[\bar{x} - ks, \bar{x} + ks]$ fordern wir:

$$\mathbb{P}\left(\Phi\left(\frac{\bar{x} + ks - \mu}{\sigma}\right) - \Phi\left(\frac{\bar{x} - ks - \mu}{\sigma}\right) \geq p\right) = 1 - \alpha \quad (26)$$

Dies führt auf ein zweidimensionales Problem in $\bar{x}$ und s , das keine geschlossene Lösung hat. Howes Approximation vereinfacht durch die Faktorisierung:

- Die Unsicherheit in $\bar{x}$ wird durch $(1 + 1/n)$ berücksichtigt (Varianz von $\bar{x}$)
- Die Unsicherheit in s^2 wird durch das χ^2 -Quantil eingefangen (Verteilung von $(n-1)s^2/\sigma^2$)

Die resultierende Formel

$$k = z_{(1+p)/2} \cdot \sqrt{\frac{(n-1)(1+1/n)}{\chi_{1-\alpha, n-1}^2}} \quad (27)$$

ist für $n \geq 10$ eine gute Approximation. Für kleinere n gibt es tabellarische Korrekturen (siehe Meeker et al., 2017).

15 Vergleich der Verfahren

15.1 Intervallbreite

Bei gleichen Daten und gleichen Parametern $(p, 1 - \alpha)$ liefern die Verfahren unterschiedlich breite Intervalle. Generell gilt:

Eigenschaft	Rangfolge
Engste Intervalle	Parametrisch (richtige Verteilung)
Breiteste Intervalle	Verteilungsfrei
Robustheit	Verteilungsfrei > Parametrisch
Rechenzeit	Normal $\ll$ Weibull

Das verteilungsfreie Intervall ist immer das konservativste (breiteste), weil es keine Verteilungsannahme ausnutzt. Im Gegenzug ist es immun gegen Modellfehler.

15.2 Wann welches Verfahren?

Tabelle 6: Empfehlungen für die Praxis

Situation	Empfehlung
$n > n_{\min}$, keine Verteilungsinformation	Verteilungsfrei
$n < n_{\min}$, Daten symmetrisch	Normal
$n < n_{\min}$, Daten rechtsschief, positiv	Lognormal oder Weibull
Lebensdauerdaten, $c < 1.5$	Weibull
Keine Verteilung passt	Mehr Daten sammeln

15.3 Rechenaufwand

- Verteilungsfrei:** $O(n \log n)$ (Sortieren)
- Normal:** $O(n)$ plus Quantilberechnung
- Lognormal:** $O(n)$ wie Normal
- Weibull GoF:** $O(N_{MC} \cdot n)$ für Monte-Carlo-KS
- Weibull Bootstrap:** $O(B \cdot n)$ für B Bootstrap-Replikationen

In der Praxis dauert der Weibull-Pfad einige Sekunden (ca. 2–5 s für $n = 30$, $B = 2000$), alle anderen Verfahren sind quasi instantan (< 100 ms).

16 Abgrenzung: TI vs. KI vs. Prädiktionsintervall

Ein häufiger Fehler in der Praxis ist die Verwechslung der drei Intervalltypen. Am Beispiel von $n = 20$ normalverteilten Messwerten mit $\bar{x} = 100$ und $s = 10$:

Tabelle 7: Drei Intervalltypen im Vergleich ($\alpha = 0.05$)

Intervalltyp	Formel	Breite
95%-KI für μ	$\bar{x} \pm t_{0.975,19} \frac{s}{\sqrt{n}}$	[95.3, 104.7]
95%-Prädiktions-I.	$\bar{x} \pm t_{0.975,19} s \sqrt{1 + \frac{1}{n}}$	[78.4, 121.6]
95/95-TI	$\bar{x} \pm k \cdot s$	[72.5, 127.5]

Das Konfidenzintervall ist mit Abstand das engste, weil es nur den *Mittelwert* einschließen muss – einen einzelnen Punkt. Das Prädiktionsintervall ist breiter, weil es einen *zukünftigen Einzelwert* abdecken muss. Das Toleranzintervall ist am breitesten, weil es *95% aller zukünftigen Werte* gleichzeitig abdecken muss, und zwar mit einer zusätzlichen Konfidenzsicherheit.

Die Breiten-Reihenfolge gilt immer:

$$|KI| < |PI| < |TI|$$

Hinweis: Wer ein KI berechnet, aber ein TI braucht, unterschätzt die Streuung der Population drastisch. Das ist einer der häufigsten statistischen Fehler in technischen Berichten.

17 Zusammenhang mit Prozessfähigkeitskennzahlen

In der Qualitätssicherung werden häufig Prozessfähigkeitskennzahlen wie C_p und C_{pk} verwendet. Es besteht ein enger Zusammenhang zu Toleranzintervallen.

17.1 Definitionen

Gegeben Spezifikationsgrenzen LSL (Lower Specification Limit) und USL (Upper Specification Limit):

$$C_p = \frac{USL - LSL}{6\sigma} \quad (28)$$

$$C_{pk} = \min\left(\frac{USL - \mu}{3\sigma}, \frac{\mu - LSL}{3\sigma}\right) \quad (29)$$

17.2 Verbindung zu Toleranzintervallen

Ein 99.73/50-Toleranzintervall (Abdeckung 99.73%, Konfidenz 50%) entspricht genau dem Bereich $\mu \pm 3\sigma$ – dem Nenner von C_p . Ein Prozess mit $C_p = 1$ hat also ein natürliches Streuband, das gerade die Spezifikationsgrenzen ausfüllt.

In der Praxis ist jedoch die *Unsicherheit* in der Schätzung von μ und σ relevant. Hier bieten Toleranzintervalle den entscheidenden Vorteil: Sie berücksichtigen die Stichprobenunsicherheit explizit über die Konfidenz $1 - \alpha$.

Satz 17.1 (TI und Prozessfähigkeit). Ein Prozess erfüllt die Spezifikation mit Abdeckung p und Konfidenz $1 - \alpha$, wenn das entsprechende Toleranzintervall vollständig innerhalb [LSL, USL] liegt:

$$\bar{x} - k \cdot s \geq LSL \quad \text{und} \quad \bar{x} + k \cdot s \leq USL \quad (30)$$

Dies ist eine *strengere* Forderung als $C_{pk} \geq 1$, weil der k -Faktor größer ist als 3 (er berücksichtigt die endliche Stichprobe). Erst für $n \rightarrow \infty$ konvergieren beide Aussagen.

Hinweis: $C_{pk} \geq 1$ aus $n = 30$ Messwerten ist *keine* Garantie, dass der Prozess dauerhaft fähig ist. Ein 95/95-TI innerhalb der Spezifikation ist die belastbarere Aussage.

18 Bootstrap-Verfahren im Detail

18.1 Warum Bootstrap?

Für die Normalverteilung existiert eine analytische Lösung (k -Faktor). Für andere Verteilungen ist dies oft nicht der Fall, insbesondere wenn:

- Die Pivotgröße $\frac{\hat{\theta} - \theta}{\text{se}}$ keine bekannte Verteilung hat
- Die Quantile der Verteilung keine einfache Funktion der Parameter sind
- Konfidenzgrenzen für Funktionale (nicht nur Parameter) gesucht sind

18.2 Parametrischer vs. nichtparametrischer Bootstrap

Parametrisch: Simuliere aus der geschätzten Verteilung $\hat{F}(\cdot; \hat{\theta})$. Nutzt die Verteilungsannahme aus, liefert engere Intervalle.

Nichtparametrisch: Ziehe mit Zurücklegen aus der empirischen Verteilung F_n . Keine Verteilungsannahme, aber breitere Intervalle und instabil bei kleinem n .

Im Weibull-Fall verwenden wir den *parametrischen* Bootstrap, weil:

1. Die Weibull-Annahme bereits durch den GoF-Test gestützt ist
2. Bei $n = 20$ –30 der nichtparametrische Bootstrap für Extremquantile ($p = 0.025, 0.975$) unzuverlässig ist
3. Die parametrische Variante die MLE-Eigenschaften (Konsistenz, Effizienz) nutzt

18.3 Konvergenzverhalten

Die Genauigkeit des Bootstrap-Toleranzintervalls hängt von der Anzahl der Replikationen B ab. Für die Perzentil-Methode gilt approximativ:

$$\text{se}(\hat{q}_\gamma) \approx \sqrt{\frac{\gamma(1-\gamma)}{B}} \cdot \frac{1}{f(\hat{q}_\gamma)} \quad (31)$$

wobei f die Dichte der Bootstrap-Verteilung ist.

Für $\gamma = 0.025$ und $B = 2000$ ergibt sich $\text{se} \approx \frac{0.156}{f(\hat{q}_{0.025})} \cdot \frac{1}{\sqrt{2000}} \approx \frac{0.0035}{f(\hat{q})}$, was für praktische Zwecke ausreichend genau ist.

Warnung: Bei $B < 500$ können die Bootstrap-Konfidenzgrenzen instabil sein. Bei sicherheitskritischen Anwendungen empfiehlt sich $B \geq 5000$.

19 Sensitivitätsanalyse

19.1 Einfluss des Signifikanzniveaus α_s

Die Wahl von α_s für den Shapiro-Wilk-Test beeinflusst die Methodenwahl:

- $\alpha_s = 0.01$ (**streng**): Normalverteilung wird seltener abgelehnt $\Rightarrow$ häufiger Normal-TI. Risiko: TI basiert auf falscher Verteilungsannahme.
- $\alpha_s = 0.10$ (**liberal**): Normalverteilung wird häufiger abgelehnt $\Rightarrow$ häufiger Lognormal/Weibull/Fallback. Risiko: Unnötig komplexes Verfahren bei fast-normalen Daten.

Der Standardwert $\alpha_s = 0.05$ ist ein praxiserprobter Kompromiss. Bei kleinem n (< 15) hat der Shapiro-Wilk-Test allerdings wenig Macht – er lehnt fast nie ab, unabhängig von der wahren Verteilung.

19.2 Einfluss von n auf die Intervallbreite

Für das Normal-TI (zweiseitig, $p = 0.95$, $1 - \alpha = 0.95$) zeigt Table 8 die relative Intervallbreite $2k \cdot s$ normiert auf σ :

Tabelle 8: Relative Breite des 95/95-Normal-TI

n	k	$2k$ (in Einheiten σ)
5	4.414	8.83
10	3.079	6.16
20	2.584	5.17
50	2.269	4.54
100	2.133	4.27
∞	1.960	3.92

Bei $n = 5$ ist das TI mehr als doppelt so breit wie bei $n \rightarrow \infty$. Die Investition in mehr Messwerte lohnt sich besonders im Bereich $n = 5$ –30.

20 Ausblick: Zensierte Daten

In der Praxis der Lebensdauerprüfung werden Tests häufig abgebrochen, bevor alle Prüflinge ausgefallen sind. Die resultierenden Daten sind *zensiert*.

20.1 Zensierungsarten

Typ-I-Zensierung (zeitlich): Der Test endet nach einer festen Zeit T . Prüflinge, die bis T nicht ausgefallen sind, liefern nur die Information „Lebensdauer $> T$ “.

Typ-II-Zensierung (anzahlbasiert): Der Test endet nach dem r -ten Ausfall. Die Lebensdauern der verbleibenden $n - r$ Prüflinge sind rechtszensiert.

Zufällige Zensierung: Prüflinge fallen zu verschiedenen Zeitpunkten aus dem Test (z. B. durch Bruch, Verlust). Häufigster Fall in der Praxis.

20.2 Auswirkung auf Toleranzintervalle

Zensierte Daten erfordern Anpassungen aller Verfahren:

- **Verteilungsfrei:** Nicht direkt anwendbar, da $x_{(n)}$ nicht beobachtet wird
- **Normal/Lognormal:** $\bar{x}$ und s müssen durch zensierungsbereinigte Schätzer ersetzt werden (z. B. Kaplan-Meier für den Median)
- **Weibull:** Die MLE-Likelihood muss um Zensierungsterme erweitert werden:

$$\ell(c, \lambda) = \sum_{i \in \mathcal{F}} \ln f(t_i) + \sum_{i \in \mathcal{C}} \ln S(t_i) \quad (32)$$

wobei $\mathcal{F}$ die Menge der beobachteten Ausfälle, $\mathcal{C}$ die Menge der zensierten Beobachtungen und $S(t) = 1 - F(t)$ die Überlebensfunktion ist.

Für Weibull ergibt sich konkret:

$$S(t) = \exp \left[- \left(\frac{t}{\lambda} \right)^c \right] \quad (33)$$

Hinweis: Die aktuelle Implementierung unterstützt noch keine zensierten Daten. Für diesen Anwendungsfall empfiehlt sich die Python-Bibliothek `lifelines` oder `reliability`, die zensierungsbereinigte MLE und Bootstrap implementieren.

21 Fehlerquellen und häufige Missverständnisse

21.1 Verwechslung von Konfidenz und Abdeckung

Ein 95/95-TI wird gelegentlich als „95%-Intervall“ abgekürzt – aber *welche* 95%? Es ist essenziell, beide Parameter anzugeben. Ein 99/50-TI (99% Abdeckung, 50% Konfidenz) ist eine völlig andere Aussage als ein 50/99-TI (50% Abdeckung, 99% Konfidenz).

21.2 Normalitätsannahme bei kleinem n

Bei $n = 10$ hat der Shapiro-Wilk-Test eine Macht von typischerweise 30–50% gegen moderate Abweichungen von der Normalverteilung. Das bedeutet: Selbst wenn die Daten *nicht* normalverteilt sind, wird H_0 in mehr als der Hälfte der Fälle *nicht* abgelehnt. Der Test „bestätigt“ also nicht die Normalität – er kann sie nur bei starken Abweichungen ablehnen.

Konsequenz: Bei kleinem n sollte domänenspezifisches Wissen über die Verteilung einfließen, nicht blind dem Testergebnis vertraut werden.

21.3 Multiple Testproblematik

Der Entscheidungsalgorithmus testet sequenziell auf Normal-, Lognormal- und Weibull-Verteilung. Jeder Test hat eine Fehlerwahrscheinlichkeit α_s . Die Gesamtwahrscheinlichkeit, mindestens eine falsche Akzeptanz zu produzieren, ist *nicht* α_s , sondern kann bis zu $1 - (1 - \alpha_s)^3 \approx 0.143$ für $\alpha_s = 0.05$ betragen.

In der Praxis ist dies kein gravierendes Problem, weil die Tests sequenziell (nicht parallel) durchgeführt werden und bei der ersten Akzeptanz abgebrochen wird. Die Prioritätsreihenfolge (Normal vor Lognormal vor Weibull) stellt sicher, dass das einfachste passende Modell gewählt wird.

22 Referenzen und weiterführende Literatur

- [1] MEEKER, W. Q., HAHN, G. J. und ESCOBAR, L. A.: *Statistical Intervals: A Guide for Practitioners and Researchers*. 2. Aufl., Wiley, 2017.
- [2] HOWE, W. G.: Two-sided tolerance limits for normal populations – some improvements. *J. Amer. Statist. Assoc.*, 64:610–620, 1969.
- [3] ISO 16269-6:2014: *Statistical interpretation of data – Part 6: Determination of statistical tolerance intervals*.
- [4] SHAPIRO, S. S. und WILK, M. B.: An analysis of variance test for normality. *Biometrika*, 52(3/4):591–611, 1965.
- [5] GUENTHER, W. C.: Tolerance intervals for univariate distributions. *Naval Res. Logist. Quart.*, 19(2):309–333, 1972.
- [6] KRISHNAMOORTHY, K. und MATHEW, T.: *Statistical Tolerance Regions: Theory, Applications, and Computation*. Wiley, 2009.
- [7] LAWLESS, J. F.: *Statistical Models and Methods for Lifetime Data*. 2. Aufl., Wiley, 2003.
- [8] NIST/SEMATECH e-Handbook of Statistical Methods: *Tolerance Intervals*. <https://www.itl.nist.gov/div898/handbook/prc/section2/prc263.htm>
- [9] WILKS, S. S.: Determination of sample sizes for setting tolerance limits. *Ann. Math. Statist.*, 12(1):91–96, 1941.

A Formelsammlung

Zum schnellen Nachschlagen – alle zentralen Formeln auf einen Blick.

A.1 Verteilungsfreies TI

Allgemein (ℓ, u beliebig):

$$\text{Konfidenz: } \text{CPTI} = F_{\text{Binom}}(d-1; n, p) \quad (34)$$

$$\text{wobei } d = u - \ell \text{ (Span)} \quad (35)$$

Optimiert (Satz 2.4):

$$d^* = \min\{d : F_{\text{Binom}}(d-1; n, p) \geq 1 - \alpha\} \quad (36)$$

$$\ell^* = \arg \min_{\ell} (x_{(\ell+d^*)} - x_{(\ell)}) \quad (37)$$

$$\text{Intervall: } [x_{(\ell^*)}, x_{(\ell^*+d^*)}] \quad (38)$$

Spezialfall ($\ell = 1, u = n$):

$$\text{Konfidenz: } C = 1 - np^{n-1} + (n-1)p^n \quad (39)$$

$$\text{Min. } n : 1 - np^{n-1} + (n-1)p^n \geq 1 - \alpha \quad (40)$$

Einseitig:

$$\text{Konfidenz: } C = 1 - p^n \quad (41)$$

$$\text{Min. } n : n \geq \frac{\ln \alpha}{\ln p} \quad (42)$$

A.2 Normal-TI

Zweiseitig:

$$\text{Intervall: } [\bar{x} - ks, \bar{x} + ks] \quad (43)$$

$$k = z_{(1+p)/2} \cdot \sqrt{\frac{(n-1)(1+1/n)}{\chi_{1-\alpha, n-1}^2}} \quad (44)$$

Einseitig:

$$\text{Intervall: } (-\infty, \bar{x} + ks] \quad (45)$$

$$k = \frac{t_{n-1, 1-\alpha, z_p \sqrt{n}}}{\sqrt{n}} \quad (46)$$

A.3 Lognormal-TI

Setze $y_i = \ln x_i$, berechne $\bar{y}$ und s_y :

$$[\exp(\bar{y} - k \cdot s_y), \exp(\bar{y} + k \cdot s_y)] \quad (47)$$

mit k wie im Normalfall.

A.4 Weibull-TI

Weibull-Dichte und Quantilfunktion:

$$f(x) = \frac{c}{\lambda} \left(\frac{x}{\lambda}\right)^{c-1} \exp\left[-\left(\frac{x}{\lambda}\right)^c\right] \quad (48)$$

$$F^{-1}(q) = \lambda (-\ln(1-q))^{1/c} \quad (49)$$

Bootstrap-Konfidenzgrenzen (B Replikationen):

$$L = Q_{\alpha/2} \left(\left\{ F^{-1}\left(\frac{1-p}{2}; \hat{c}^{(b)}, \hat{\lambda}^{(b)}\right) \right\}_{b=1}^B \right) \quad (50)$$

$$U = Q_{1-\alpha/2} \left(\left\{ F^{-1}\left(\frac{1+p}{2}; \hat{c}^{(b)}, \hat{\lambda}^{(b)}\right) \right\}_{b=1}^B \right) \quad (51)$$

A.5 Shapiro-Wilk-Teststatistik

$$W = \frac{(\sum_{i=1}^n a_i x_{(i)})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad \text{mit} \quad \mathbf{a} = \frac{\mathbf{V}^{-1} \mathbf{m}}{\|\mathbf{V}^{-1} \mathbf{m}\|} \quad (52)$$

A.6 KS-Teststatistik (Weibull-GoF)

$$D_n = \sup_x |F_n(x) - F(x; \hat{c}, \hat{\lambda})| \quad (53)$$

Monte-Carlo- p -Wert (N_{MC} Replikationen):

$$p_{\text{MC}} = \frac{1}{N_{\text{MC}}} \sum_{j=1}^{N_{\text{MC}}} \mathbf{1}[D_n^{(j)} \geq D_n] \quad (54)$$

A.7 Prozessfähigkeit

$$C_p = \frac{\text{USL} - \text{LSL}}{6\sigma} \quad (55)$$

$$C_{pk} = \min\left(\frac{\text{USL} - \mu}{3\sigma}, \frac{\mu - \text{LSL}}{3\sigma}\right) \quad (56)$$

TI-basierte Spezifikationsprüfung:

$$\text{LSL} \leq \bar{x} - ks \quad \text{und} \quad \bar{x} + ks \leq \text{USL} \quad (57)$$